

强化学习入门（小鸭子版）：从策略梯度到 PPO，让一只 800 克的小鸭子自己学会动

目录

1 从「教它走路」到「给它打分」	3
1.1 先看它在做什么	3
1.2 为什么不能像教机械臂那样教它	4
1.3 换一种监督信号：不给答案，只给分数	6
1.4 输入输出到底是什么：61 个数进，14 个数出	7
1.5 一步的分数怎么给：奖励表与回报	9
1.6 策略与价值：贯穿全篇的两个量	10
1.7 训练数据是它自己跑出来的	11
1.8 这一讲要走的路线	11
1.9 术语对照表	12
2 强化学习方法分类	13
2.1 第一个划分：学不学环境模型	13
2.2 第二个划分：学什么——基于价值还是基于策略	13
2.3 Actor-Critic：横跨两类的混合架构	14
2.4 第三个划分：采数据的策略和学的策略是不是同一个	14
2.5 把常见算法放上这张地图	14
2.6 本节小结	15
3 认识这只小鸭子：从硬件到仿真	15
3.1 它是什么：800 克、25 厘米、两条腿	16
3.2 骨架与关节：14 个舵机怎么分布，第 15 个在哪	17
3.3 大脑与神经：板子、总线、传感器、电池	17
3.4 它平时怎么被驱动：50 赫兹的控制环	17
3.5 仿真里的这只鸭子：三个模型，各有各的用处	18
3.6 舵机不是理想的 PD：BAM 执行器模型	18
3.7 每个回合都不完全一样：域随机化	19

3.8 mlab: 一次开几千只鸭子的练功房	20
3.9 代码地图: 一节讲义对一个模块	20
4 v1 REINFORCE: 先自己试, 试好了就多做	21
4.1 直觉: 没有标准答案, 怎么知道该往哪调	21
4.2 好动作加概率, 坏动作减概率	22
4.3 要写成式子的话	22
4.4 一轮训练长什么样: 采一批、算回报、更新一次	23
4.5 代码走读: v1 版训练循环	23
4.6 实验: 它真能走起来, 但走得难看	25
4.7 毛病在哪: 回报的噪声淹没了学习信号	27
4.8 本节小结	27
5 v2 A2C: 请一位评分员	27
5.1 直觉: 跟「平均水平」比, 不是跟零比	27
5.2 评分员是什么: 价值与优势	28
5.3 要写成式子的话	29
5.4 代码走读: v1 到 v2 改了什么	30
5.5 实验: 动作幅度打开了, 但时不时被推坏	31
5.6 毛病在哪: 更新的步子没人管	31
5.7 本节小结	32
6 v3 PPO: 给更新的步子加护栏	34
6.1 直觉: 一次别改太多	34
6.2 护栏怎么加: 概率比值与 clip	34
6.3 顺手省数据: 一段数据反复训几轮	35
6.4 学习率自己调: 动得太猛就减速	35
6.5 要写成式子的话	36
6.6 代码走读: v2 到 v3 改了什么	36
6.7 实验: 三个算法同台, 行走任务收口	37
6.8 本节小结	38
7 一套 PPO, 换个奖励就是另一件事	39
7.1 谱系总览: 一个仓里三十三个任务, 算法一行没改	40
7.2 脚下装上轮子: 轮滑	41
7.3 原地转起来: 旋转	42
7.4 低头, 用嘴尖碰到地上的东西: 取物	42
7.5 翻过去再站起来: 前滚翻	43
7.6 插一段: 目标可以完全不在观测里	45
7.7 插一段: “慢才是最优” 怎么写进奖励	46
7.8 写奖励的几条规矩	46

7.9 一个身体，多个策略：观测布局与随时换脑	47
7.10 奖励表和课程表都在环境这一侧	47
8 本讲小结	48
8.1 一条演进链：每一步为什么发生	48
8.2 一张小结表：同一套算法，几个不同的动作	49
8.3 还能往哪走	49




图 1: 四只小鸭子摆在不同姿态下。**舵机和连杆是外露的**，从这张图上就能一节节数过去：髋、膝、踝各一组，脖子与头另有四个。这也是它便宜的原因之一——没有外壳要做。（厂商照片，Pollen Robotics）

一只 800 克、25 厘米高的双足小鸭子，站在一块什么都没有的平地上。它有 14 个舵机，每秒被指挥 50 次。没有人教它怎么走。

它学会的这些动作全都是自己试出来的：按指令朝任意方向走，脚下换成轮子后滑行，原地飞快旋转，低头用嘴尖碰到地面上的东西，向前翻一个跟头再站回来。**这里没有一个动作是人教的**。没有示教数据，没有动作捕捉，没有任何一条“这一步该做什么”的标准答案，只有一个能打分的函数，和大量的失败。

这一讲讲的就是这件事怎么可能。我们会先把“学走路”翻译成强化学习的语言，建立一张不会混淆的方法分类地图，然后沿着地图上一条主线，从最朴素的做法出发，每讲完一个算法就在同一个任务上跑给你看——看到它的毛病，再引出下一个算法——一路走到工业界在用的那套配方。最后把同一套配方原样换到别的动作上，看它能学出多少花样。

全篇只在仿真里进行。

1 从「教它走路」到「给它打分」

1.1 先看它在做什么

一只 800 克、25 厘米高的小鸭子站在一块空平地上。




图 2: 训练中的一屏。这张图是叠画出来的，不是一个场地里的实况。并行训练是「多个环境、每只鸭子一个环境」，每个环境是一份独立的物理世界，鸭子之间既看不见也碰不到；渲染器把邻近几个环境的鸭子追加进同一张画面，才有了这个效果。真实训练时同时跑的是 4096 个。

它身上有 14 个舵机（两条腿各 5 个，脖子和头 4 个）。每 20 毫秒，一个神经网络读一遍它此刻的姿态，给这 14 个舵机各下一个目标角度；舵机去追那个角度，物理世界演进 20 毫秒，网络再读一遍。一秒钟五十轮，中间没有人。

现在给它一个任务：**按指令的速度在平地上走**。往前多快、往侧多快、转多快，每个回合随机给一组；走稳了、跟上了、没摔，就给分。摔了就重置，从站姿再来一遍。

这一讲要讲的就是这个网络怎么从”完全不会”变成”稳稳地走”。下面先把上面这段白话里的每个东西，换成强化学习的说法。

1.2 为什么不能像教机械臂那样教它

教机器人做事最直接的办法是**示范给它看**：人操作一遍，把每一时刻的动作记下来，让网络去模仿。这套办法在很多地方管用——带着机械臂的手把一个杯子拿起来，人的手怎么动、夹爪怎么合，都能一一录下。

放到这只鸭子身上，它立刻失效，有三个层次的原因。

第一层，采不到。走路不是一个姿势，是 14 个关节以每秒 50 次的频率协调发力。人有两条腿，但人的腿和这只鸭子的腿在长度比例、质量分布、关节限位上都不一样，“我怎么走”照搬过去它站不住。就




图 3: 五个动作，一行一个；行内三张是同一个动作的三个瞬间，按时间顺序。同一套算法、同一份代码，只改了奖励表。

算你想逐关节遥控操作，一只手也管不了 14 个自由度，更别说要在毫秒级上保持配合。

第二层，示范不告诉你哪种更好。假设真采到了一段能走的示范，模仿学习的目标是“贴近这段示范”。但示范里没有“这样走比那样走更省力”、“这个步幅更抗推”这类信息——监督信号只回答“这一步该做什么”，不回答“这一步做得好不好”。想要机器人自己找到比示范者更好的做法，模仿这条路上没有这个概念。

第三层，走错了没人救。闭环控制里误差会滚雪球：机器人的动作影响下一时刻的状态，一旦偏离到示范数据没覆盖过的姿态，网络就两眼一抹黑——那里没有标签。而一只 25 厘米高、重心偏上的双足机器人，偏离到“没见过的姿态”只需要一次跟跑。

三层的根源是同一个：示教给的是“该做什么”，而我们需要的是“做得怎么样”。

1.3 换一种监督信号：不给答案，只给分数

“做得怎么样”用一个标量就能表达：**奖励**（reward，记作 r ）。

强化学习把世界切成两半：**智能体**（agent）和**环境**（environment）。智能体就是那个神经网络；除它之外的一切——机器人的身体、地面、重力、指令是怎么生成的——都算环境。

一次交互长这样：

1. 环境处在某个**状态**（state, s_t ），把它交给智能体；
2. 智能体选一个**动作**（action, a_t ）；
3. 环境执行这个动作，物理演进一个控制周期（20 毫秒），到达新状态 s_{t+1} ，并给出这一步的奖励 r_t ；
4. 回到第 1 步。

这样一条 $(s_0, a_0, r_0, s_1, a_1, r_1, \dots)$ 的序列叫一条**轨迹**（trajectory）。轨迹不会无限长，它因为两种原因结束：

- **终止**（termination）：出事了——鸭子摔倒、姿态坏到没救。
- **截断**（truncation）：时间到了——回合有最大长度，到点就重置，不代表失败。

一条从开始到结束的轨迹叫一个**回合**（episode）。走路这个任务的回合是 1000 步，也就是 20 秒。区分终止和截断很要紧，第 6 节讲 PPO 时会用到：摔倒了就是摔倒了，后面没有价值可言；而时间到了被打断，机器人本来还能继续挣分——这两种情况在算“未来还能拿多少分”时不能一样对待。

换成打分之后，两件事跟着变了。

一是监督信号的性质。模仿学习的每条样本都带着动作标签，属于监督学习；强化学习没有标签，只有事后的评分，而且评分往往是延迟的——现在这一步好不好，可能要几十步之后摔了才知道。

二是数据的来源。模仿学习的数据集是事先采好的、静态的；强化学习的训练数据是机器人自己跑出来的。这一点在 1.7 节展开。




图 4: 智能体与环境的闭环。环境交出状态 s_t ，智能体出动作 a_t ，环境执行完给出新状态和这一步的奖励 r_t 。**强化学习与模仿学习的全部差别，就在多出来的那条奖励线上**——模仿学习只有状态与动作那两条。

1.4 输入输出到底是什么：61 个数进，14 个数出

那个网络叫**策略**（policy，记作 π_θ ， θ 是它的参数）。它做的事只有一件：**读一串数，写一串数**。

- 读进去的叫**观测**（observation， o_t ），61 个浮点数；
- 写出来的叫**动作**（action， a_t ），14 个浮点数。

这两串数具体是什么量、什么单位，值得说清楚——它决定了这个策略在真机上要接什么。

输入这 61 个数分成两部分。前 48 个是**本体感受**（proprioception），机器人对自己身体的感觉，全部来自机身上的传感器：

段	维数	是什么量	单位
姿态（重力方向在机身坐标系里的投影）	3	无量纲的方向余弦	—
机身角速度（IMU 陀螺仪）	3	角速度	弧度/秒
关节角度（14 个舵机的编码器读数）	14	角度相对站立姿态的偏移	弧度
关节角速度	14	角速度	弧度/秒
上一步下发的动作	14	目标角度偏移	弧度

后 13 个是**指令**（command）——这一回合要它做什么，由环境随机生成：




图 5: 策略两侧的接口。左边 61 维观测按来源分成四段，右边 14 维动作是关节目标角度；策略不给电压也不给力矩，从角度到电流那一步在舵机内部的位置环里完成。图里的单位就是代码里实际用的单位。

指令	维数	是什么量	单位
线速度与转向	3	前进、侧移、转向	米/秒、米/秒、弧度/秒
头部姿态	4	颈与头四个关节的目标偏移	弧度
身体姿态	6	躯干位置与朝向偏移（走路任务里权重极小）	米、弧度

输出这 14 个数全是同一种量：关节目标角度的偏移（弧度），加到站立姿态上就是要去的角度。策略不直接给力矩，也不直接给电压。它说“左膝去到 +0.3 弧度”，舵机内部的位置环去追这个目标，该出多少电流由舵机自己决定。这一层间接让学习容易得多——策略不必学习力学，只需要学“摆什么姿势”。

14 个关节这么分布：

编号	部位	关节
0-4	左腿	髌偏航、髌滚转、髌俯仰、膝、踝
5-8	颈与头	颈俯仰、头俯仰、头偏航、头滚转
9-13	右腿	髌偏航、髌滚转、髌俯仰、膝、踝

每个舵机能出的力矩大约 1 牛 $\cdot$ 米。这个数字后面很关键：它小得需要认真对待，第 3 节会解释为什么不能把它当成一个理想的位置伺服。

两件事现在先记下，第 7 节会回收：

- **所有任务共用同一份 61 维观测布局。**某个任务用不到某个指令槽位时，那几个数字被填零而不是删掉。这看起来浪费，实则有意——它让同一个身体上可以随时切换不同的策略，因为输入格式一样。
- **状态与观测的区别。**严格地说策略拿到的是观测 o_t ，不是环境的完整状态 s_t ——环境里还有它看不到的东西（地面摩擦系数、电池当前电压）。能看全叫完全可观测，看不全叫部分可观测。本篇在仿真里把该给的都给了，两者不再区分，统一写 s_t 。

1.5 一步的分数怎么给：奖励表与回报

奖励 r_t 是**每一步都有的**即时分数，不是等回合结束才给。但要最大化的不是某一步，而是**长期累计**——很多好动作的收益是延迟的：为了迈出稳的一步，此刻可能要把重心压低，那一瞬间的分数并不高。

于是引入**回报** (return, R_t)：从第 t 步往后，所有奖励的折扣累加

$$R_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots = \sum_{k \geq 0} \gamma^k r_{t+k}$$

其中 $\gamma \in (0, 1)$ 叫**折扣因子** (discount factor)，本篇取 0.99。它给“多远的未来还算数”定一个尺度：越接近 1 越看重远期，越小越短视。取 0.99 意味着大约 100 步（2 秒）之后的奖励还剩三分之一的分量——对走路这种任务，两秒足够涵盖好几个步态周期。折扣还有个技术上的好处：它让无限长的和收敛。




图 6: 折扣因子 γ 决定它看多远。左：往后第 k 步的奖励在回报里的权重 γ^k ；右：换算成“有效视野在一个回合里占多长”。本篇取 $\gamma = 0.99$ ——半衰期 69 步、有效视野约 100 步，而走路一个回合是 1000 步（20 秒 / 50 赫兹）。取 0.9 就只顾眼前 0.2 秒，取 0.999 则把整个回合都算进来。

到这里定义都齐了，但“奖励”听起来还是抽象。实际上它**不是一个函数，而是一张加权项表**：环境每一步把表里每一项各算一遍，乘上权重，加起来，就是这一步的 r_t 。

走路这个任务的表一共 **16 项**（下表按权重绝对值排，从环境配置里逐项读出来的，本篇只读它、不改它）：

要它做的	权重	不许做的	权重
腾空时间落在 0.125–0.300 秒	+3.0	抬脚高度偏离目标	−2.0
跟上线速度指令	+2.0	关节顶到行程限位	−1.0
跟上转向指令	+2.0	腿撞到躯干	−1.0
躯干保持直立	+2.0	摆动腿抬得过高	−0.25
跟上头部姿态指令	+2.0	动作变化太快	−0.1（见下面第三条）
腿关节贴近站立姿态	+1.0	脚打滑	−0.1
		躯干角速度过大	−0.05
		整机角动量过大	−0.02

（还有两项权重是 0：躯干姿态跟踪与头部下垂惩罚。它们是留给课程表从 0 拉起来的，不是“不用”。7.8 节规矩（6）讲的就是这类项为什么要晚上。）

先看这张表的形状：要它做的 6 项、不许做的 8 项，而“不许做的”里最重的一项（抬脚高度偏离目标，−2.0）和最轻的一项（整机角动量，−0.02）差一百倍。这个量级差不是随手给的：越是“物理上不得不做”的事（动态动作必然带来角动量），惩罚就要给得越轻，否则它会把动作本身掐死。

三个机制值得单独讲清，因为它们解释了这张表为什么这么写。

一、跟踪型的项是高斯形状的。“跟上线速度指令”不是简单地拿误差去扣分，而是把误差送进 $\exp(-\text{误差}^2/\sigma^2)$ 。好处是：误差小的时候分数接近满分且变化平缓，误差大的时候分数迅速趋近 0 而不是无限扣下去——不会因为一次大偏差就把整个回合的分数毁掉。这里的 σ 要取“你还在意的误差”，不是“最大可能的误差”：取太大，小误差之间几乎没有区分度，策略就没有动力去精细跟踪。

二、有些项带门限。“脚打滑”那一项只在速度指令不接近零时才计算。原因很实际：指令是“站住不动”的时候，脚本来就该踩死在地上，这时候按打滑扣分等于惩罚正确行为。

三、有一项的权重会随训练变化。“动作变化太快”这一项，起初权重只有 −0.1，之后分段增大，到第 1500 次迭代才到 −1.0。这是有意的：平滑约束太早拉满，“什么都不做”就成了最优解——不动就不会有动作变化，也就不会被扣分。必须先让它学会迈步，再慢慢要求它迈得优雅。

这三条不是这个任务特有的技巧，而是写奖励的通用规矩。第 6 节会在多个任务的奖励表并排之后，把这类规矩集中讲一遍。

1.6 策略与价值：贯穿全篇的两个量

策略 $\pi_\theta(a | s)$ ：在状态 s 下选择动作 a 的概率。注意它是一个**概率分布**而不是一个确定的动作——这一点很重要，因为强化学习必须**探索**（exploration）：如果策略每次都输出同一个动作，它永远不会知道别的动作是不是更好。本篇的策略输出一个高斯分布的均值，标准差是一组可训练的参数；训练时从这个分布里采样（带探索），评测时直接取均值（不带探索，成绩才可复现）。




图 7: 策略在连续动作上输出的不是一个数, 是一个分布: 网络给出均值 $\mu_\theta(s)$ 与标准差 σ , 真正执行的动作是从这个高斯里采出来的。 σ 就是探索的幅度——第 3 节那个熵奖励调的正是它。

价值函数 (value function) $V(s)$: 从状态 s 出发, 按当前策略走下去, 期望能拿到多少回报。它回答“现在这个局面值多少钱”。注意它依赖于策略——同一个局面, 好策略能挣得更多。

这两个量对应后面所有算法的两条主线: **直接调整策略**, 还是**先学会评估局面再据此行动**。第 2 节会把这条分岔画成一张图。

关于 π_θ 有一句要说在前面: **后面三个算法换的都不是它**。REINFORCE、A2C、PPO 用的是同一个网络结构、同一份 61 进 14 出的接口, 换的只是“拿到一批数据之后, 用什么公式去调它的参数”。到第 6 节让它学会各种花样时, 连参数怎么调都不换了, 换的是奖励表。

1.7 训练数据是它自己跑出来的

有一个词后面会反复出现: **rollout**。它指的是“让当前策略在环境里连续跑一段, 把这一段经历记下来”。在强化学习里, rollout **就是训练数据本身**, 没有别的来源。这带来两个直接后果:

- **数据要现产**。每一轮训练之前都得先跑一段, 所以仿真速度直接决定训练速度。这也是为什么这一讲从头到尾在仿真里做, 而且要一次开几千个环境同时跑。
- **数据会过期**。用旧策略跑出来的数据, 对新策略未必还适用。这件事有多严重、能不能忽略, 是第 2 节要讲的一个重要划分。

1.8 这一讲要走的路线

贯穿全讲的基础任务只有一个: **让这只鸭子按速度指令在平地上行走**。

选它当入门载体有三个理由: 它不需要任何示教数据 (正是 1.2 节的第一种情形); “跟上速度、保持直立”这个分数很好写; 而且它在仿真里可以大规模并行试错, 单卡就能复现。

方法上走一条**三级阶梯**，每一级都是一个完整的算法，在**同一个任务、同一份预算**下跑出来对照：

- **v1 REINFORCE**：最朴素的策略梯度。能走起来，但**站不住**。评测里 6400 个环境步摔了 40 次。
- **v2 A2C**：请一个“评分员”来当参照物。换来的是一次**不摔**，分并没有更高。
- **v3 PPO**：给每次更新加上护栏。用**更小**的动作拿到**更高**的分，工业级配方。

这三行各自对应第 4、5、6 节末尾的一次实测，**每一行的重点都不是“分涨了多少”**。3.6 节会说清为什么“每步平均奖励”这个指标对“频繁摔倒”几乎是瞎的。

为了让对照干净，三个版本刻意做到**只有算法不同**：同一个环境、同一个网络结构、同一份训练预算，评测口径也完全一致。**版本之间的差异 (diff) 就是这一讲的知识点**——读懂三个文件的区别，就读懂了从 REINFORCE 到 PPO 的演进。

讲完 PPO，第 6 节把同一套代码原样搬到别的动作上：轮滑、原地旋转、鼻尖取物、前滚翻。那时候变的只有奖励函数。

1.9 术语对照表

后面各节会反复用到这些词。中英文与符号一并列出，读英文文献时对得上。

中文	English	符号	在这个任务里是什么
智能体	agent	—	那个 61 进 14 出的神经网络
环境	environment	—	机器人身体 + 地面 + 重力 + 指令生成器
状态 / 观测	state / observation	s_t / o_t	61 个数：48 维本体感受 + 13 维指令
动作	action	a_t	14 个关节的目标角度偏移（弧度）
一步	timestep	t	20 毫秒（50 赫兹控制周期）
奖励	reward	r_t	一张 16 项的加权表，每步算一次
回报	return	R_t	奖励的折扣累加
折扣因子	discount factor	γ	0.99
回合	episode	—	从站立开始，到摔倒（终止）或时间到（截断）
终止 / 截断	termination / truncation	—	摔了 / 到点了，两者不能一样对待
轨迹	trajectory	τ	一个回合里的 (s, a, r) 序列
策略	policy	π_θ	动作概率分布，训练时采样、评测时取均值
价值函数	value function	$V(s)$	当前局面按现行策略还能挣多少
优势	advantage	A_t	这个动作比该局面的平均水平好多少（第 4 节）
探索	exploration	σ	动作分布的标准差，可训练
轨迹采集	rollout	—	让策略在环境里跑一段并记下来

2 强化学习方法分类

强化学习的算法出了名的多而杂，名字一大把，很容易读着读着就不知道自己在哪。这一节不求全，只建立一张**不会混淆的地图**：用三个问题把方法分开，每个问题都对应一个真实的工程后果。

这一节不出现公式。

2.1 第一个划分：学不学环境模型

第一个问题是：**要不要让机器人先学会“环境是怎么运作的”？**

- **有模型** (model-based)：先学一个环境模型——给定当前状态和动作，预测下一个状态会是什么。有了这个模型，就可以在“脑内”推演：不用真的动，先想几步再决定。
- **无模型** (model-free)：不学环境，直接学“该怎么动”。环境是个黑盒，只管往里送动作、接住奖励。

工程上的取舍很直接。有模型的样本效率高——同一份真实经验可以在脑内反复推演；但它多引入了一个可能学错的东西，模型偏差会被推演放大。无模型的路子笨但踏实，在仿真里试错很便宜的场合尤其划算。

这一讲全程走无模型。因为我们在仿真里，试错成本低到可以一次开几千个环境，样本效率不是瓶颈。

2.2 第二个划分：学什么——基于价值还是基于策略

第二个问题是：**网络输出的到底是什么？**

- **基于价值** (value-based)：网络学的是“每个动作值多少分”。用的时候挑分最高的那个动作。经典代表是 Q-learning 和 DQN。
- **基于策略** (policy-based)：网络直接学“该做什么动作”，输出一个动作或一个动作分布。经典代表就是策略梯度那一家。

这个划分在我们这个任务上不是偏好问题，而是可行性问题。

基于价值的方法要“挑分最高的动作”，这在动作是**离散**的时候很自然——比如上下左右四个选择，四个都算一遍取最大。但这只鸭子的动作是**14 个连续的关节角度**，可能的组合是连续无穷的，没法一个个算过来取最大。

所以这一讲走基于策略这一支。这不是因为它更先进，而是因为连续高维动作空间基本堵死了另一条路。

2.3 Actor-Critic：横跨两类的混合架构

上面两类不是非此即彼。实际最常用的是把它们缝在一起，叫 **Actor-Critic**：

- **Actor**（演员）是策略网络：负责输出动作。这是基于策略的那一半。
- **Critic**（评论员）是价值网络：负责评估局面值多少分。这是基于价值的那一半。

它们的分工是：actor 决定做什么，critic 告诉 actor “你刚才那个决定，比这个局面的平均水平好还是差”。actor 拿这个评价去调整自己。

critic 只在训练时存在。训练完把 actor 单独拿走就能用，critic 扔掉。这带来一个很有用的后果——既然 critic 反正不部署，那就可以让它看到 actor 看不到的信息（仿真器里的“天眼”数据），把分打得更准。第 5 节会具体用到这一点。

本讲的 v2 和 v3 都是 Actor-Critic 架构；v1 只有 actor，恰好用来看清“没有 critic 会怎样”。

2.4 第三个划分：采数据的策略和学的策略是不是同一个

第三个问题最不直观，但它的工程后果最大：**你手上这批数据，是“现在这个策略”跑出来的吗？**

- **on-policy**（同策略）：训练数据必须来自当前策略。用它更新一次之后，这批数据就作废了——因为策略已经变了，这些数据描述的是“旧的我”。
- **off-policy**（异策略）：数据可以来自别的策略，包括很久以前的自己。于是可以把经历存在一个池子里反复抽用。

后果是什么？on-policy 的数据**用一次就扔**，所以它吃数据；off-policy 能把每条经验反复用，样本效率高得多，但它要处理“用旧数据学新策略”带来的偏差，训练稳定性通常更难对付。

本讲三级阶梯全是 on-policy。理由和 3.1 一样：仿真里数据便宜，我们宁可多跑几轮换一个更稳的训练过程。

2.5 把常见算法放上这张地图

三个划分交叉起来，常见算法各自的位置就清楚了：

算法	学环境模型	学什么	数据来源
Q-learning · DQN	不学	价值	off-policy
REINFORCE	不学	策略	on-policy
A2C · A3C	不学	策略 + 价值	on-policy
TRPO · PPO	不学	策略 + 价值	on-policy
DDPG · TD3 · SAC	不学	策略 + 价值	off-policy
Dreamer 一类	学	策略 + 价值	二者皆有




图 8: 方法分类地图 (取自 OpenAI Spinning Up)。它画出了本节前两个划分: 先分「学不学环境模型」, 无模型那一支再分「基于策略」与「基于价值」。本讲走的是左下角那条——无模型·基于策略, 图里的 Policy Gradient → A2C/A3C → PPO 正好是第 5-7 节的三级阶梯。第三个划分 (on-policy / off-policy) 不在这张图上, 见 2.4 节。

本讲的路线是: 无模型·基于策略 (Actor-Critic) ·on-policy。在这条线上, 从最朴素的 REINFORCE 出发, 一路走到 PPO。

地图上其余的格子不是被否定了, 只是不在这一讲的范围里。

2.6 本节小结

三个问题, 三句话:

- **要不要先学环境?** 不学——仿真里试错便宜, 不值得多引入一个会学错的东西。
- **输出价值还是动作?** 输出动作——14 个连续关节角没法“逐个算过来取最大”。
- **数据能不能重复用?** 这一讲不重复用——宁可多跑, 换训练过程更稳。

三个“这一讲的选择”都不是因为它们最先进, 而是因为它们最匹配眼下的处境: 连续高维动作、仿真里可以海量试错、想要一个尽量少踩坑的入门路径。

3 认识这只小鸭子：从硬件到仿真

前三节讲的都是通用的道理, 从这一节起落到具体这台机器上。

要说清一件事：**介绍硬件不是为了教你怎么装一台机器人**，而是为了让你知道**被控对象是什么**。第 2 节那 61 个数字和 14 个数字凭什么是那样，答案全在这一节里。

3.1 它是什么：800 克、25 厘米、两条腿



图 9: 25 厘米高是什么概念：它站在桌上，人伸手过去就能把它整个握住。机身上外露的黑色方块就是舵机，脚是橙色的塑料底板。（厂商照片，Pollen Robotics）

高 × 宽	25 厘米 × 14 厘米
重量	不到 800 克
关节	15 个舵机（Dynamixel XL330 一类的微型数字舵机）
计算	Rockchip RK3566，带 AI 加速器，1 GB 内存 / 32 GB 存储
传感	前置摄像头、8×8 飞行时间深度矩阵、 两个 惯性测量单元（躯干与头各一）
其他	麦克风、扬声器、NFC、Wi-Fi、蓝牙
电池	可换的 NP-F550 相机电池（2600 毫安时），续航约 1 小时
控制频率	50 赫兹

它比一瓶矿泉水重一点，放在桌上大约一个笔记本电脑屏幕那么高。整机与全套软件开源，定价 399 美元一档，这个价位是它值得作为教学载体的原因之一——摔坏一台的代价，和摔坏一台人形机器人不在一个量级。

这个尺度决定了很多事。它轻，所以摔了不容易坏，可以放心让它反复摔；它小，所以关节能出的力矩也小（约 1 牛·米，相当于在 10 厘米长的杠杆末端挂 1 公斤）。后面 3.6 节会说明，正是这个“力矩

很小”的事实，让我们不能把它的舵机当成一个理想的位置伺服来仿真。

3.2 骨架与关节：14 个舵机怎么分布，第 15 个在哪

它的运动来自 14 个舵机，分布已经在 2.3 节列过：每条腿 5 个，颈与头 4 个。开篇那张四只鸭子的照片可以对着数——舵机和连杆全是外露的。

需要补一句的是真机上有 15 个舵机——多出来那个驱动一张能开合的嘴。那不是装饰：真机靠这张嘴叼起小物件，官方演示里就有这一项。但仿真模型里嘴是一个被动连杆，不参与运动控制，因为本篇要学的动作（走路、起身、踢球、轮滑）都用不到它。

这是“仿真只建与任务有关的自由度”的第一个具体例子。多建一个自由度就多一份物理计算、多一维需要学习的动作，而它对我们要学的动作没有贡献。

站立姿态（也就是每个回合的起点）大致是：髋俯仰约 26 度、踝约 26 度、膝接近伸直、颈与头各约 20 度。这个姿态是调过的——躯干比几何中心略微前移，让重心正好落在踝关节轴上方；早先的版本重心偏后，起身策略学出来的动作是把头往前甩当配重。

3.3 大脑与神经：板子、总线、传感器、电池

- **计算板**：瑞芯微 RK3566，带一个 AI 加速器，1 GB 内存、32 GB 存储。巴掌大小，功耗低到能靠一块相机电池供一小时。
- **舵机总线**：所有舵机挂在一条串行总线上，板子通过它读关节角、下发目标角度。注意是一条总线：15 个舵机轮流通信，这是后面“指令延迟”那一项的物理来源。
- **两个惯性测量单元**：一个在躯干、一个在头部。给出姿态（四元数）、角速度、加速度。第 2.2 节那 48 维本体感受里，“它现在是正着的还是歪的”就来自这里。为什么要两个：头是可以独立转动的，只靠躯干那一个测不出头的朝向。
- **摄像头与 8×8 深度矩阵**：头部有一个前置摄像头和一个飞行时间深度传感器（输出 8×8 的距离矩阵，相当于一个极低分辨率的激光雷达）。本篇的策略完全不用它们——走路、起身这些动作靠本体感受就够，视觉与深度是另一类任务的入口。
- **电池**：一块可换的 NP-F550 相机电池，标称 7.2 伏、2600 毫安时，续航约一小时。仿真里把工作电压建在 6.5 到 8.2 伏之间——满电到亏电的实际区间。这个区间 3.7 节要用到。

3.4 它平时怎么被驱动：50 赫兹的控制环

真机上跑着一组各管一件事的常驻服务，它们用本地套接字上的一套 JSON-RPC 通信：控制环与电机总线、配置与配网、固件更新、蓝牙、手柄输入、摄像头与音频、深度传感器。其中只有控制环那一个服务碰机器人本体，而且它的循环从不等待任何别的服务——跨服务读数据一律读缓存里的最新值，不做同步调用。这条约束是为了保住 50 赫兹的确定性：一个卡住的摄像头服务不能把控制环拖慢。

一个控制周期（20 毫秒）里发生的事，顺序是固定的：

1. 板子从总线上读回 14 个关节的角度与角速度，从惯性单元读回姿态；
2. 这些数字连同当前指令拼成那 61 维观测；
3. 策略算一次，输出 14 个目标角度；
4. 目标角度下发到总线，各舵机的位置环去追它；
5. 20 毫秒后回到第 1 步。

把这个数字变具体很有必要，因为后面几处都要用它：回合长度是多少步、指令延迟是几个周期、“动作变化太快”这一项在惩罚什么，全都以这 20 毫秒为单位。

3.5 仿真里的这只鸭子：三个模型，各有各的用处

仿真里的机器人是一份 MJCF 文件（MuJoCo 的模型格式），从 CAD 导出、带上质量与惯量。这里有三份，不是一份：

模型	特点	谁在用
走路模型	躯干与头的碰撞体被剥掉	走路、轮滑
全碰撞模型	身体能真的躺在地上	起身、坐站、取物、踢球
轮滑模型	脚下多四个被动轮	轮滑、旋转

为什么要剥掉碰撞体？因为走路任务里“摔倒”只需要被判定为终止，不需要精确模拟躯干砸在地上怎么弹。少一批碰撞体就少一批接触检测，训练明显更快。而起身任务恰恰相反——它必须从“躺在地上”开始，身体与地面的接触是任务的核心，那批碰撞体一个都不能少。

同一个道理再说一次：**仿真只建与任务有关的东西**。这是把算力花在有用的地方。

3.6 舵机不是理想的 PD：BAM 执行器模型

这一节解释一个容易被跳过、但在这个尺度上非做不可的事。

最省事的仿真做法是：把舵机当成一个理想的位置伺服——你给目标角度，它就以某个刚度去追，力矩要多少有多少（顶多设一个上限）。大机器人上这个近似常常够用。

在这只鸭子上它不够用，因为它的力矩本来就只有约 1 牛·米。这意味着：

- 电池电压掉一点，能出的力矩就少一截；
- 关节转得快的时候，反电动势会把可用力矩进一步压下去；
- 减速箱里的摩擦不是一个常数，它随负载变化。

三件事叠起来，理想 PD 与真实舵机的差距不是“精度问题”，而是**量级问题**。用理想 PD 训出来的步态，可能是靠一个它其实拿不出来的力矩来源站住的——那样的策略在真实力矩下站不住。

所以这里用的是一个把舵机建到**电压控制律**层面的模型：输入是目标角度，中间算过电压、反电动势、库仑摩擦与随负载变化的摩擦，输出才是力矩。




图 10: 同一个踢球动作，左边是仿真、右边是真机。这一对图说明本篇为什么要在执行器上下功夫：两边的姿态、支撑腿的位置、摆腿的时机都能对上，而对得上的前提是仿真里的舵机不是一个理想的位置伺服。

3.7 每个回合都不完全一样：域随机化

如果每次训练面对的都是同一台机器、同一块地面，策略很容易学出一个**只对这一组参数成立的巧合**：它精确地利用了某个摩擦系数、某个电压，换一点就不成立。

对策叫**域随机化**（domain randomization）：每个回合开始时，把那些“本来就不确定”的量重新摇一遍。这里摇的是：

量	为什么摇它
电池电压	电量从满到亏，工作电压在 6.5–8.2 伏之间变
负载下的电压跌落	多个舵机同时出力时，总线电压会被拉低
指令延迟（3–6 个周期）	总线通信与固件处理都要时间，不是零延迟
关节摩擦	装配公差、磨损、温度都会改变它
质量与惯量、质心位置	电池位置、线束走向都会影响
惯性单元的安装误差	传感器不可能装得绝对正
编码器标定偏差	每个关节的零位都有一点偏差
训练中随机推一把	让它学会被扰动之后自己找回来

于是策略见到的不是一台固定的机器，而是一**族略有差别的机器**。它学出来的东西必须对整族都成立，这就排除了那些只对一组参数成立的巧合。

上游还建了一套齿隙模型（每个舵机串一个 ± 1 度的空程），用来对付减速箱里的间隙。本

篇不用它。

3.8 mujlab：一次开几千只鸭子的练功房

强化学习靠海量试错吃饭。一个环境一步一步跑，一天也训不出来。这里用的仿真框架叫 **mujlab**，它做两件事：

一是把 **MuJoCo** 搬上 **GPU** 并行。它用 GPU 版的 MuJoCo (MuJoCo Warp)，**同时跑几千个互相独立的物理世界**——每个世界里一只鸭子。注意这句话的重点：不是“一个场地里站着几千只鸭子”，而是“几千份各自独立的世界，每份里一只”。它们之间既看不见也碰不到，各有自己的速度指令、自己的回合计数、自己的重置时机。

二是把环境拆成**一组管理器**。场景、观测、奖励、终止条件、指令生成、域随机化、课程表，每一样都是一个可插拔的配置项。第 2.5 节那张奖励表，在代码里就是奖励管理器的一份配置。这个设计有个重要后果，第 7 节会讲：**奖励与课程表都在环境这一侧，换掉训练算法它们照样生效。**

并行开多少个合适？实测过一条吞吐曲线（只算仿真、不含学习）：

并行环境数	2048	4096	8192	16384
每秒仿真步	15.98	15.00	10.70	5.49
每墙钟秒采到的环境步（百万）	0.033	0.061	0.088	0.090

读法：2048 到 4096 几乎免费（数据翻倍而每秒步数只掉 6%），说明那时候瓶颈还在“启动一次计算”的开销上；4096 到 8192 净赚约 1.45 倍；再往上完全打平——吞吐到顶了。**甜点在 8192。**

顺带一个反直觉的观察：**显存从来不是约束**。16384 个环境时张量占用不到 1 GB。瓶颈在核函数启动开销与 CPU 侧的编排，不在算力也不在显存——所以换一张显存更大的卡并不会更快。

3.9 代码地图：一节讲义对一个模块

这一讲从下一节开始，每一个一级标题都对应代码仓库里的一个文件。

讲义	代码	内容
第 4 节	<code>code/train_v1_reinforce.py</code>	走路 · REINFORCE
第 5 节	<code>code/train_v2_a2c.py</code>	走路 · A2C
第 6 节	<code>code/train_v3_ppo.py</code>	走路 · PPO
第 7 节	同一个 <code>train_v3_ppo.py</code> ，只改 TASK 一行	换成别的动作

另外三个共用件：

- `code/env.py` —— 把 mujlab 的任务包成薄接口。**这是整个目录里唯一与机器人有关的文件**，顶部一行 TASK 决定跑哪个任务。

- `code/model.py` —— 三个版本共用的 ActorCritic 网络与优势估计工具。三个算法用**同一个网络类**, 所以版本之间的差距不会被网络结构的差异污染。
- `code/rollout.py` —— 按统一口径评测并录像。

三份训练脚本都是同一个 PyTorch Lightning 结构: 一个在线采样的 Dataset、一个 LightningDataModule、一个负责算 loss 的 LightningModule, 入口统一是 `trainer.fit(model, data)`。要调的超参就写在第一次用到它的地方, 没有命令行参数层。

装环境与跑起来:

```
# 按 pyproject 装依赖, 不用 pip
uv sync
# 冒烟: 环境构得起来、观测维度对得上
uv run pytest tests/ -q
# 训一个策略, 权重落到 RL_DUCK_CKPT_ROOT
uv run python code/train_v3_ppo.py
```

建议横向对照着读那三份脚本。它们的差异就是接下来三节的全部内容。

4 v1 REINFORCE: 先自己试, 试好了就多做

4.1 直觉: 没有标准答案, 怎么知道该往哪调

监督学习里, 网络参数怎么调是清楚的: 有标准答案, 算出误差, 往误差变小的方向走。

强化学习没有标准答案。它手上只有一堆“我做了这个, 后来拿到这么多分”的记录。问题变成了: **只知道分数, 怎么知道参数该往哪调?**

答案朴素得让人意外:

凡是最后拿分多的那些动作, 让它们以后更容易被选中; 拿分少的, 让它们更不容易。

就这一句。它不需要知道“正确动作”是什么, 也不需要知道环境是怎么运作的。它只需要能对同一个局面尝试不同的动作, 然后看结果。

打个比方。你在一个陌生城市找一家好吃的面馆, 没有地图也没有点评。你能做的就是随便试: 这家好吃, 下次更可能再来; 那家难吃, 下次绕开。试的次数足够多, 你的选择分布就会自己向好吃的那些倾斜。你从头到尾没有得到过“哪家最好吃”这个标准答案, 但你的行为改善了。

这就是**策略梯度** (policy gradient) 的全部直觉。

4.2 好动作加概率, 坏动作减概率

把上面那句话落到网络上。

策略输出的是一个**概率分布** (2.6 节说过)。所谓“让某个动作更容易被选中”, 就是**提高它在那个分布下的概率**。而概率是网络参数的函数, 所以“提高概率”就有了明确的梯度方向。

于是每一条采到的数据 (s_t, a_t, R_t) 都给出一个调整指令:

- 沿着“让 a_t 在状态 s_t 下概率变大”的方向,
- 步长按 R_t 的大小来定。

R_t 大就大步走, R_t 小就小步走。如果 R_t 是负的, 就朝反方向走——也就是压低这个动作的概率。

这里有一个必须处理的问题: **回报的绝对值没有意义, 只有相对高低有意义**。

假设某个任务里所有动作的回报都在 100 到 110 之间。按上面的规则, 每一个动作都会被大幅提高概率 (因为 R_t 都是很大的正数), 好动作和坏动作都在涨, 只是涨得多少不同——这等于什么都没学到, 而且梯度还特别大, 训练会炸。

所以实践中必须**减掉一个参照值**。v1 用的是最朴素的做法: **减掉这一批数据的平均回报**。这样一半的动作变成正、一半变成负, “比平均好的加概率、比平均差的减概率”, 方向就对了。再除以这批数据的标准差, 把尺度归一化, 梯度大小也稳住了。

那个被减掉的参照值有个名字, 叫**基线** (baseline)。v1 的基线是一个常数 (整批均值); 第 5 节要做的事, 就是把这个常数换成一个**学出来的函数**。

4.3 要写成式子的话

上面那套直觉有严格的表述, 叫**策略梯度定理**。结论直接用, 不推导:

$$\nabla_{\theta} J(\theta) = \mathbb{E} \left[\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R_t \right]$$

左边 $J(\theta)$ 是“按这个策略走, 期望能拿多少回报”——正是我们想最大化的东西。右边说: 它的梯度可以直接从**采样数据里估出来**, 不需要知道环境的任何内部结构。

怎么读这个式子:

- $\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$ 是“让这个动作概率变大”的方向;
- R_t 是这个方向该被放大多少倍 (负数就反向);
- 求和与期望的意思是: 把采到的所有 (s_t, a_t) 都这样处理, 然后平均。

加上基线之后, R_t 换成 $R_t - b$, 其中 b 是基线。可以证明: **只要基线不依赖于动作, 减掉它不改变梯度的期望**, 但能显著降低估计的方差。这就是为什么可以放心减。

跳过这一节不影响读懂后面。要记住的只有一句：**梯度** = “提高这个动作概率的方向” × “这个动作比参照值好多少”。

4.4 一轮训练长什么样：采一批、算回报、更新一次

v1 的一次迭代分三步：

第一步，采样。用当前策略在环境里跑一段，记录每一步的观测、动作、奖励。本篇的配置是 4096 个环境同时跑、每个环境跑 24 步，所以一次迭代拿到 $4096 \times 24 = 98304$ 条数据。

第二步，算回报。对每一步算出它的折扣回报 R_t 。做法是从后往前累加：

$$R_t = r_t + \gamma R_{t+1}$$

倒着走是因为第 t 步的回报要用到第 $t+1$ 步的结果。遇到回合结束就把递推截断——不能把下一个回合的奖励算进上一个回合。

第三步，更新一次。用这批数据算一次梯度，走一步，然后**把数据扔掉**。下一轮重新采。这就是 2.4 节说的 on-policy：数据只配当前策略，用过即弃。

一次迭代 = 采一段 + 更新一次。本篇跑 6000 次迭代。

4.5 代码走读：v1 版训练循环

代码在 `code/train_v1_reinforce.py`。它是标准的 PyTorch Lightning 结构，三个类各管一件事：

DuckRolloutDataset (在线采样)。它的 `sample_rollout()` 就是 4.4 节的第一、二步：

```
# 攒够一批再更新，逐步更新方差太大
for step in range(self.num_steps_per_env):
    # 采样阶段不建图，省显存
    with torch.no_grad():
        actions, _log_probs, _values, _means, _stds = self.model.act(obs,
        ↪ critic_obs)
    # 4096 个环境同时走一步
    next_obs, next_critic_obs, rewards, dones, _info = env.step(actions)
    # 观测、动作、奖励、done 都要存，回报要靠它们倒着算
    ...
# done 处截断，别把下个回合算进来
returns = reward_to_go(reward_steps, done_steps, self.gamma)
# v1 的基线只有整批均值这个常数，没有 critic
```

```

advantages = returns - returns.mean()
# 归一化, 免得批与批之间步长忽大忽小
advantages = advantages / (advantages.std() + 1.0e-8)

```

注意 `torch.no_grad()`: 采样阶段不需要梯度, 那是更新阶段的事。也注意最后两行——那就是 4.2 节说的“减掉整批均值再除以标准差”, **v1 的基线只有这两行**。

DuckData (把环境交给 Trainer)。它长期持有环境对象, 因为仿真状态要跨迭代连续推进, 不能每轮新建。它的 `train_dataloader()` 每个 epoch 重建一次数据集——重建就意味着重新采样, 这正是 on-policy 的要求。

DuckLightningReinforce (算 loss)。整个算法的核心就是 `training_step` 里这几行:

```

# 策略输出的是分布, 不是一个动作
distribution = self.model.action_distribution(batch["obs"])
# 14 个关节独立, log 概率相加
log_probs = distribution.log_prob(batch["actions"]).sum(dim=-1)
# 熵越大探索越广
entropy = distribution.entropy().sum(dim=-1)
# 优势为正就把这个动作的概率推高
policy_loss = -(log_probs * batch["advantages"]).mean()
# 单独拿出来, 好调它的权重
entropy_loss = entropy.mean()
# 减号: 鼓励熵, 不是惩罚熵
loss = policy_loss - self.entropy_coef * entropy_loss

```

第四行就是 4.3 节那个式子——前面加负号是因为优化器做的是**最小化**, 而我们要最大化回报。

最后一行多了一项**熵奖励**。熵衡量动作分布有多宽: 熵大意味着策略还在广泛尝试, 熵小意味着它已经很确定。在 loss 里减去一个熵项 (也就是奖励高熵), 是为了防止策略过早收敛到一个次优动作上不再探索。系数取 0.01。

还有一处值得注意:

```

# v1 没有 critic, 只优化 actor 和那个标准差
params = list(self.model.actor.parameters()) + [self.model.std]
# 标准差是可学的: 探索幅度自己收敛
self.optimizer = torch.optim.Adam(params, lr=self.learning_rate)

```

只有 actor 和动作标准差进优化器。网络类里虽然带着 critic, 但 REINFORCE 用不到它——刻意让它闲置, 这样三个版本才能共用同一个网络类, 对照时不掺入结构差异。

4.6 实验：它真能走起来，但走得难看




图 11: v1 REINFORCE 的学习曲线。浅色是逐迭代原始值，深色是滑动平均。它确实在学，但爬到 0.06 附近就走平了，而且是彻底走平，不是放慢。

它真的走起来了。前一千多次迭代曲线一路向上，鸭子从原地抽搐变成能往前挪。这件事本身值得停一下：我们没有给过任何一个“正确动作”的示范，奖励表里也没有一句话描述“怎么走”，只有“跟上速度指令”“别摔”“别抖”这些评分标准。14 个舵机的协调是它自己试出来的。

但它很早就见顶了。从大约第 1300 次迭代起，曲线在 0.060 附近彻底走平，不动了，不是变慢。后面几千次迭代、上亿个环境步，换来的提升接近于零。

按统一口径评测（最终权重、确定性动作、16 个环境各跑 400 步）：

指标	v1 REINFORCE
评测平均奖励	0.127
摔倒终止	40 次（6400 个环境步里）
动作幅度均值	0.248

先看最后那一行，它是这一节真正的结果：**40 次摔倒**。

16 个环境各跑 400 步，一共 6400 个环境步，摔了 40 次，平均每个环境摔两次半。也就是说这个策略走不了几秒就会倒，倒了重置，再走几秒再倒。

而它的“评测平均奖励”是 0.127，比下一节那个不摔倒的 v2 (0.122) 还高一点点。这件事值得停下来想清楚，因为它是整篇里最容易骗人的一处：每次摔倒之后环境把鸭子重置成一个漂亮的站姿，而站姿附近是最容易拿分的地方。于是“频繁摔倒 + 频繁重置”这个策略在“每步平均奖励”这个指标上并不难看。一个只看平均奖励的人会得出“v1 和 v2 差不多”的结论，而看视频的人一眼就分得出来。

这也是本篇反复强调“看画面判定”的具体原因（7.8 节规矩（5）讲的是同一件事的奖励设计版本：别在坏状态上给正分）。




图 12: v1 REINFORCE 最终策略的一整个回合，十二帧覆盖 1000 步（相邻帧 85 步）。这一回合它一次没倒，但十二帧里找不到一次干净的迈步——两只脚基本一直踩在身体正下方；第 316 步整个躯干前倾到头快贴地，之后又立回来。真正在动的是头，一路来回甩。

“走得难看”就是从这十二帧上看出来的：步子很小、几乎不抬脚，靠上身晃动把身体往前带。

4.7 毛病在哪：回报的噪声淹没了学习信号

v1 能学，但学得慢，而且很早就见顶。原因不在“梯度算错了”——策略梯度定理是对的，v1 的估计也是无偏的。问题在**方差**。

想一下 R_t 是什么：从第 t 步往后所有奖励的折扣累加。这个数取决于**这一整条轨迹后面发生的所有事**——包括与第 t 步那个动作毫无关系的事。

举个具体的：鸭子在第 10 步做了一个很好的迈步动作，但第 40 步因为一个和它无关的扰动摔倒了，于是第 10 步的回报也很低。算法据此得出结论：“第 10 步那个动作不好，压低它的概率”。**它把功劳和罪责算错了人。**

这个现象叫**信用分配**（credit assignment）问题。用整条轨迹的回报当权重，噪声非常大：同一个状态、同一个动作，两次采样得到的 R_t 可能差很远。减掉整批均值只解决了“尺度”，没解决“噪声”——那个常数基线对所有状态是同一个值，而不同状态的合理参照本来就该不同。站得稳的局面和快摔倒的局面，“平均水平”显然不一样。

需要一个随状态变化的参照值。而“某个状态值多少分”这件事，2.6 节已经定义过了——它就是价值函数 $V(s)$ 。下一节把那个常数换成它。

4.8 本节小结

- 策略梯度的全部直觉是一句话：**拿分多的动作加概率，拿分少的减概率。**
- 必须减掉一个参照值（基线），否则学不到东西且梯度会炸。v1 的基线是整批均值。
- 一次迭代 = 采一段数据 + 更新一次 + 把数据扔掉（on-policy）。
- 它的毛病是方差：用整条轨迹的回报当权重，会把功劳和罪责算错人。

5 v2 A2C: 请一位评分员

5.1 直觉：跟「平均水平」比，不是跟零比

v1 的问题是参照值太粗——所有状态共用一个常数。

改进的直觉很自然：**每个局面应该有自己的参照值。**

还是找面馆那个比方。你是一条美食街上，随便一家都不错；在另一条街上，能吃饱就算走运。同样一顿“七分满意”的饭，在美食街上是失望，在另一条街上是惊喜。如果你用同一个标准（比如“及格线六分”）去评判两条街上的所有选择，你学到的东西就是错的。

正确的做法是：拿这次的结果，跟“这个局面本来预期能拿多少”去比。比预期好就加概率，比预期差就减。这个“本来预期能拿多少”就是价值函数 $V(s)$ ，而“实际减预期”这个差值有个名字，叫**优势** (advantage)。

5.2 评分员是什么：价值与优势

引入第二个网络——**critic**，它学的就是 $V(s)$ ：给它一个局面，它预测“按当前策略走下去，期望还能拿多少回报”。

于是原来的权重 $R_t - \bar{R}$ （实际回报减整批均值）换成

$$A_t = R_t - V(s_t)$$

实际拿到的，减去这个局面本来预期能拿到的。这就是优势。

优势的符号有非常直白的含义：

- $A_t > 0$ ：这个动作比“在这个局面下的平均表现”更好 → 加概率。
- $A_t < 0$ ：比平均更差 → 减概率。

对比 v1：v1 是“跟全局平均比”，v2 是“跟本局面的预期比”。后者把“局面本身好不好”这个因素扣掉了，剩下的才是“这个动作贡献了多少”。这正是 4.7 节要的东西。




图 13: actor 与 critic 各自在做什么。critic 回归 returns 把 V 估准，两个 V 相减得到优势 A （一步版 $A = r + \gamma V(s') - V(s)$ ，本篇用的是多步平滑的 GAE），再拿 A 去加权策略梯度更新 actor。

Actor 和 critic 一起训练，各有各的目标：

- **actor** 的目标：让优势大的动作概率变大（和 v1 一样，只是权重换成了 A_t ）。

- **critic** 的目标: 让自己的预测更准, 也就是让 $V(s_t)$ 贴近实际回报。这是一个普通的回归问题, 用均方误差。

这就是 **Actor-Critic**, 2.3 节在地图上标过的位置。

一个可以白拿的好处。 critic 只在训练时存在 (2.3 节说过)。既然它不部署, 那就可以让它看到 actor 看不到的东西——比如仿真器里精确的躯干线速度、没有加编码器偏置的真实关节角、脚底的接触力。这些“天眼”信息让它估得更准, 而 actor 依然只看那 61 个真机拿得到的数字。本篇的代码就是这么做的, **两边的维度实测差 15**: actor 61 维, critic 76 维。多出来的那 15 维全是真机上拿不到、仿真器里却是现成的量——基座真实线速度 3、双脚离地高度 2、双脚腾空时间 2、双脚是否触地 2、接触力 6。这几项恰好都是“评价这一步走得好不好”最需要的信息, 而它们又都是装不上传感器的 (真机没有全局速度计, 脚底也没有力传感器)。**critic 只在训练时存在, 所以它可以用这些量; actor 要被搬到真机上, 所以一个都不能用。**

5.3 要写成式子的话

优势的定義可以更一般: $A(s, a) = Q(s, a) - V(s)$, 其中 $Q(s, a)$ 是“在状态 s 做动作 a , 之后按策略走能拿多少”。 $A_t = R_t - V(s_t)$ 是它的一个采样估计。

实践中不直接用 $R_t - V(s_t)$, 而是用一个叫 **GAE** (广义优势估计) 的东西。它的动机是这样的:

- 用 $R_t - V(s_t)$: R_t 是真实采到的, 所以**无偏**, 但它包含整条轨迹的噪声, **方差大**。
- 只往前看一步 $r_t + \gamma V(s_{t+1}) - V(s_t)$: **方差小**, 但严重依赖 critic 估得准不准, critic 不准就有**偏**。

GAE 用一个参数 $\lambda \in [0, 1]$ 在这两端之间连续插值:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t), \quad A_t^{\text{GAE}} = \sum_{k \geq 0} (\gamma \lambda)^k \delta_{t+k}$$

$\lambda = 0$ 退化成只看一步 (低方差高偏差), $\lambda = 1$ 退化成完整回报 (无偏高方差)。本篇取 $\lambda = 0.95$, 偏向低方差那一端。

实现上同样是从后往前递推, 一次扫描就能算完整段:

$$A_t = \delta_t + \gamma \lambda \cdot A_{t+1}$$

跳过这一节不影响读懂后面。要记住的是: **优势 = 实际减预期**; GAE 是一个在“准”和“稳”之间调节的旋钮, 本篇调在偏稳那一侧。

5.4 代码走读: v1 到 v2 改了什么

code/train_v2_a2c.py 与 v1 的结构完全一样, 差异集中在两处。

关键变化一: 优势不再用常数基线, 改用 critic 估值 + GAE。

v1 是:

```
# v1: 回报照旧这样算
returns = reward_to_go(reward_steps, done_steps, self.gamma)
# v1: 基线是一个与状态无关的常数
advantages = returns - returns.mean()
```

v2 换成:

```
# (T, N, 1)    critic 给每一步一个" 这个局面值多少分"
values = ...
# (N, 1)       最后一步之后再估一次, 用来接上被截断的尾巴
next_value = ...
# 多步平滑,    调偏差与方差
advantages, returns = compute_gae(rewards, dones, values, next_value, gamma, lam)
# 同样要归一化
advantages = (advantages - advantages.mean()) / (advantages.std() + 1.0e-8)
```

compute_gae 就是 5.3 节那个从后往前的递推, 它同时返回优势和 critic 要回归的目标 (returns = advantages + values)。

关键变化二: loss 多了一项 value_loss。

v1 的 loss 只有策略项和熵项; v2 加上 critic 的回归项:

```
# critic 的活: 把回报回归准
value_loss = (returns - values_pred).pow(2).mean()
# 三项一起反传
loss = policy_loss + self.value_loss_coef * value_loss - self.entropy_coef *
    ↪ entropy_loss
```

对应地, 优化器现在要管整个网络, 不再只管 actor:

```
# v2 起 actor 与 critic 一起优化
self.optimizer = torch.optim.Adam(self.model.parameters(), lr=self.learning_rate)
```

“只改两处”说的是算法上的改动, 不是文件级的差异。把两份脚本按函数逐个比过 (去掉 docstring 与注释之后比源码): 18 个函数里 5 个逐字相同, 8 个内容不同, v1 那份多一个 reward_to_go (v2 用

GAE 之后不再需要它)。

那 8 个“内容不同”里,真正承载算法差异的只有 `sample_rollout`(优势怎么算)与 `training_step`(loss 多一项)这两个;其余六个是**连带改动**——`__init__` 多存了 critic 相关的超参、`configure_optimizers` 从“只管 actor”变成“管整个网络”、`main / run_training / setup / train_dataloader` 换了 run 名与算法标签。

这个数字值得说清,因为“只改两处”如果按字面理解,读者一 diff 就会觉得被骗了。**真正的对照保证在别处**: 同一个 ActorCritic 网络类、同一份超参、同一个环境与奖励表、同一套评测口径。算法之外的东西一样,才是“只有算法不同”的实义。

5.5 实验: 动作幅度打开了, 但时不时被推坏

v2 跑满 6000 迭代, 按统一口径评测 (最终权重、确定性动作、16 环境 $\times$ 400 步):

指标	v1 REINFORCE	v2 A2C
评测平均奖励	0.127	0.122
摔倒终止	40 次	0 次
动作幅度均值	0.248	0.332

这张表只有一行是重点: **摔倒从 40 次变成 0 次**。

平均奖励几乎没变 ($0.127 \rightarrow 0.122$, 甚至略降), 但策略从“走几秒就倒”变成了“6400 个环境步一次没倒”。加一个 critic 换来的是**站得住**, 不是“分更高”。

为什么会这样, 4.7 节已经把机理讲完了: 常数基线对所有状态用同一个参照值, 于是“站得稳的局面”和“快要摔倒的局面”被同等对待, 策略学不会区分它们。换成价值函数之后, “这一步比这个局面的平均水平好还是差”这个判断才有意义——而“快摔倒的局面里做了个救回来的动作”正是靠这个判断才能被加强。

代价写在“动作幅度均值”那一行: $0.248 \rightarrow 0.332$, 动作变猛了三成。

站得住不是白来的。v2 敢押上更大的动作 (这正是“有了可信的参照值才敢下决定”的表现), 但它没有任何机制约束“一次别改太多”——所以它的动作幅度一路涨, 下一节 v3 会看到, PPO 用更小的动作 (0.271) 拿到更高的分 (0.155)。**v2 的问题是“学过头了”, 不是“没学会”**。5.6 节讲这个。

5.6 毛病在哪: 更新的步子没人管

v2 比 v1 好, 但它引入了一个新问题, 而且这个问题是**策略梯度**这一类方法共有的。

回到 4.2 节那个规则: “沿着让这个动作概率变大的方向走, 步长按优势定”。问题是: **走多远算合适?**

- 走太小, 学得慢。




图 14: v2 A2C 的学习曲线。它一路爬到 0.10 以上还没走平，而 v1 在 0.06 就停住了。

- 走太大，策略可能一步跨到一个糟糕的区域——而且回不来。

为什么回不来？这是 on-policy 特有的陷阱。策略一变，下一轮采到的数据就来自新策略。如果这一步把策略推坏了，下一轮采到的全是坏数据，基于坏数据再更新一次，只会更坏。**它没有一个“退回去”的机制**——监督学习里数据集是固定的，走错一步下次还能纠回来；强化学习里数据是策略自己产的，走错一步连数据都跟着坏掉。

而“合适的步长”没法用一个固定的学习率解决，因为它依赖于当前局面：有时候优势很大，同样的学习率就会造成很大的策略变化；有时候优势很小，同样的学习率几乎什么都没动。

需要一个机制，直接限制“策略变化的幅度”本身，而不是限制学习率。这正是 PPO 做的事。

5.7 本节小结

- v1 的常数基线换成**随状态变化的价值函数**，权重从“实际回报”变成“优势 = 实际减预期”。
- 这需要第二个网络 critic。它只在训练时存在，所以可以让它看到 actor 看不到的信息。
- GAE 是在“无偏但噪声大”与“低噪声但依赖 critic”之间的一个旋钮，本篇取 0.95。
- 代码上只改了两处：优势怎么算、loss 多一项。
- 新毛病：更新的步子没人管，一步走坏了就回不来。




图 15: v2 A2C 最终策略的一整个回合，取样与上一张相同。它比 v1 稳得多：两脚分开站住，第 316 步到第 828 步这七帧几乎一模一样 —— 姿态确实稳了，但这一段里它没有再迈步。

6 v3 PPO: 给更新的步子加护栏

6.1 直觉：一次别改太多

5.6 节的结论是：要限制“策略变化的幅度”。

那就直接限制它。这个想法有个正式名字叫**信赖域** (trust region)：在当前策略周围划一个“可信区域”，每次更新只允许在这个区域内动。区域内的数据还算适用，出了区域就不可信了。

TRPO 是这个想法的严格实现——它用一个约束优化问题精确地限制策略变化。但它实现复杂、计算贵。**PPO 是同一个想法的一个便宜得多的实现**，它不解约束优化，而是用一个巧妙的 loss 形状达到近似的效果。效果几乎一样好，代码量少一个数量级——这是它成为工业界默认选择的原因。

一句话概括 PPO：**如果这次更新想让某个动作的概率变化超过一定比例，就把超出的那部分收益“剪掉”，让它没有继续推的动力。**

6.2 护栏怎么加：概率比值与 clip

怎么衡量“策略变了多少”？用**概率比值**：

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}$$

分母是**采样时**那个策略给这个动作的概率，分子是**当前**（已经更新过几次的）策略给的概率。比值等于 1 表示没变；大于 1 表示这个动作变得更容易被选；小于 1 表示更不容易。

于是“限制策略变化”就变成“限制这个比值别离 1 太远”。PPO 的做法是：

$$L = \min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) \cdot A_t)$$

其中 ϵ 是允许的变化幅度，本篇取 0.2（也就是允许概率变化 $\pm 20\%$ ）。

这个式子怎么起作用，分两种情况看就清楚了：

- **优势为正**（这是个好动作，想加概率）：比值涨到 $1 + \epsilon$ 之后，clip 把它按住， L 不再随比值增大而增大——**继续推没有收益了**，梯度归零。
- **优势为负**（坏动作，想减概率）：比值降到 $1 - \epsilon$ 之后同理被按住。

而 $\min$ 的作用是保证护栏只在“我们想推的那个方向”上生效：如果策略已经跑到区域外面、而且是朝着更糟的方向，梯度仍然能把它拉回来。

这就是全部的护栏。没有约束优化，没有二阶导数，就是一个 $\min$ 和一个 clip 。




图 16: clip 目标的形状 (PPO 原论文图 1)。横轴是概率比值 r , 纵轴是单个样本的目标值。左: 优势为正时, r 涨过 $1 + \epsilon$ 之后曲线变平——再往那个方向推没有额外收益。右: 优势为负时, r 跌破 $1 - \epsilon$ 之后同样变平。红点是 $r = 1$ (新旧策略相同) 的位置。

6.3 顺手省数据：一段数据反复训几轮

护栏还带来一个额外的好处，而且是很实在的好处。

v1 和 v2 都是“采一段、更新一次、扔掉”。为什么不能多更新几次？因为更新一次之后策略就变了，这段数据不再来自当前策略——再用就有偏差。

但 PPO 有护栏。既然它能保证策略不会跑太远，那么这段数据在“跑太远之前”都还算适用。于是可以：

- 把一段 rollout 切成几个 minibatch；
- 在这段数据上反复训几轮（本篇 5 轮，每轮 4 个 minibatch）。

同一批数据被用了 5 次而不是 1 次。**样本效率直接提升数倍**，而这正是同样的仿真预算下 PPO 能比 v1/v2 走得好得多的主要原因之一。

注意这不是“变成 off-policy 了”。off-policy 是“可以用很久以前的数据”；PPO 只是“当前这一小批数据用几遍”，仍然是 on-policy 的框架，用完这一批照样扔。

6.4 学习率自己调：动得太猛就减速

还有一个实用件。 ϵ 限制了单个动作的概率变化，但整体策略变了多少还有一个更直接的度量：**新旧策略之间的 KL 散度**。

PPO 常配一个自适应规则：

- 如果这一轮的 KL 明显超过目标值 (本篇目标 0.01), 说明动得太猛 → **调小学习率**;
- 如果明显低于目标值, 说明太保守 → **调大学习率**。

这样就不用手调学习率随训练进程怎么变化——它自己跟着走。

6.5 要写成式子的话

PPO 的完整 loss 有三项:

$$L = \underbrace{-\mathbb{E}[\min(r_t A_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) A_t)]}_{\text{策略项 (带护栏)}} + c_v \underbrace{\mathbb{E}[(V_\theta(s_t) - R_t)^2]}_{\text{价值回归}} - c_e \underbrace{\mathbb{E}[\mathcal{H}[\pi_\theta]]}_{\text{熵奖励}}$$

三项分别对应: actor 带护栏地往优势大的方向走、critic 回归实际回报、熵项防止过早收窄。本篇取 $c_v = 1.0$ 、 $c_e = 0.01$ 、 $\epsilon = 0.2$ 。

和 v2 的 loss 比, 唯一的形状变化就是策略项从 $-\log \pi \cdot A$ 变成了那个 $\min(\text{clip}(\dots))$ 。其余两项一字未动。

6.6 代码走读: v2 到 v3 改了什么

code/train_v3_ppo.py 与 v2 的差异有三处。

关键变化一: clip——用概率比值把更新夹在信赖域内。

这要求采样时就记下“旧策略”给每个动作的对数概率, 因为更新时策略已经变了、补不回来。所以 v3 的采样循环多存了几个量:

```
actions, log_probs, values, means, stds = self.model.act(obs, critic_obs)
# log_probs / means / stds 都要存下来 ——它们是“旧策略”的记录,
# 后面算概率比值与 KL 都要拿它当参照; 不存就没法判断" 这一步跨了多远"。
```

更新时:

```
# 新旧策略在同一个动作上的概率比值
ratio = torch.exp(log_probs_new - batch["old_log_probs"])
# 没有限制的那一项
surrogate = ratio * batch["advantages"]
# 把比值夹在 1±
surrogate_clipped = torch.clamp(ratio, 1.0 - self.clip_param, 1.0 + self.clip_param)
    ↪ * batch["advantages"]
# 取小的那个: 越界之后再推没有收益
policy_loss = -torch.min(surrogate, surrogate_clipped).mean()
```


四行，就是 6.2 节那个式子。

关键变化二：一段 rollout 切成多个 minibatch、反复训几轮。

```
# 同一批数据反复用 5 轮
for _ in range(self.num_learning_epochs):
    # 每轮再切成 4 个小批
    for mb in self.minibatches(batch, self.num_mini_batches):
        # 算 loss、反传、更新；clip 保证反复用也不跑飞
        ...
```

v1/v2 这里只有一次更新。就是这个双层循环把样本效率提上去的。

关键变化三：按 KL 自适应调学习率。

```
# 这一轮更新把策略推远了多少
kl = self.approx_kl(batch, means_new, stds_new)
# 推太远就减速，推太近就加速
adapt_learning_rate_to_kl(self.optimizer, kl, self.desired_kl)
```

`adapt_learning_rate_to_kl` 是一个十几行的小工具：KL 太大就把学习率乘 0.5，太小就乘 1.5，并夹在一个上下限之间。

同样把两份按函数比过：5 个逐字相同、8 个内容不同、v3 多出十个新函数（KL 自适应学习率、minibatch 切分、单批 loss、几个 Lightning 钩子等）。和 5.4 节一样，“**三处**”说的是**算法上的改动**——承载它的是 `sample_rollout`（多存旧策略的对数概率）与 `training_step`（clip 与多轮复用），其余是把这三件事接进 Lightning 生命周期所需的脚手架。

三处算法改动，就是从“能学”到“工业级”的全部距离。

6.7 实验：三个算法同台，行走任务收口

三个版本用**完全相同**的口径跑：同一个环境、同一个网络结构、4096 个并行环境 × 每轮 24 步 × 6000 次迭代。评测同样统一：各自的最终权重、确定性动作（取分布均值，不掺探索噪声）、16 个环境各跑 400 步。

版本	算法	评测平均奖励	摔倒终止	动作幅度均值	脚离地时间
v1	REINFORCE	0.127	40 次	0.248	——
v2	A2C	0.122	0 次	0.332	0.025 秒
v3	PPO	0.155	0 次	0.271	0.123 秒

这张表要横着读两遍，因为单看任何一列都会读错。

第一遍看“摔倒终止”。v1 摔 40 次，v2 和 v3 一次不摔。这是 v1 到 v2 那一步换来的东西——而它在“评测平均奖励”那一列**看不出来**：v1 的 0.127 甚至比 v2 的 0.122 高一点，因为每次摔倒后的重置都把鸭子放回一个好拿分的站姿。**平均奖励对“频繁摔倒”这件事几乎不敏感。**

第二遍看后两列。v2 和 v3 都不摔了，差别在动作质量：v2 用**更大的动作**（0.332 对 0.271）拿到**更低的分**（0.122 对 0.155），而它的脚离地时间只有 v3 的五分之一——它在用力蹭地，v3 才是真在走。这是 v2 到 v3 那一步换来的东西。

v1→v2 换的是“站得住”，v2→v3 换的是“走得好”。两步各修一个毛病，而没有任何单一指标能同时说清这两件事。

为什么这张表用的是评测数字，而不是训练曲线上的数。训练时记的那个平均奖励，在 v2/v3 上包含了一项 v1 没有的东西：回合因超时结束时，为了不让“时间到”被当成“失败”，要给最后一步补一个价值估计 ($\gamma V(s)$)。v1 没有 critic，也就没有这一项。实测这一项把 v2/v3 的训练日志抬高了 **7.3%**（4915200 个环境步里 0.075% 是超时步，均值从 0.1204 抬到 0.1292）。**拿加过这一项的数去和没加的比，纵轴就不是同一把尺子。**评测那条路径不含这一项，三档同一套口径，所以表里用它。下面那张曲线仍然值得看，但看的是**形状**，不是纵轴上的绝对值。

这张图比表格说得更清楚，有三件事值得指着看：

一，**v1 和 v2 在最开始那一段几乎重合。**前七千万个环境步里两条线缠在一起——因为那一段两者学的是同一件事（“别摔”），而那件事对基线的质量不敏感。分野出现在之后：v1 在 0.060 附近彻底走平，v2 继续爬到 0.10 以上。**基线换成价值函数，换来的是“学得更远”，不是“学得更快”。**

二，**v3 那条红线上来得又快又高，但它前期在抖。**那些锯齿是 clip 与 KL 自适应学习率在起作用的样子：一旦一步走猛了，KL 变大，学习率被压下来，曲线回落一点再爬。**护栏是让曲线跌下去还能回来，不是让它变平滑。**v2 那条蓝线同样有锯齿，但它的锯齿更深、恢复更慢。

三，**v3 在两千多迭代就把主要的分挣完了。**之后到 6000 迭代那一段基本是横的。6.3 节说数据复用把样本效率提上来了，这就是它的样子：同样的经验量，v3 在 v2 还在爬坡的地方已经收口。

6.8 本节小结

- PPO 的核心是一个护栏：**用概率比值衡量策略变了多少，超出 $\pm 20\%$ 就把收益剪掉。**
- 它是信赖域思想的便宜实现——同样的效果，一个 min 加一个 clip 就够，不需要 TRPO 那套约束优化。
- 有了护栏，一段数据就可以反复训几轮（本篇 5 轮 $\times$ 4 个 minibatch），样本效率提升数倍。
- 再配一个按 KL 自适应的学习率，就不用手调它随训练怎么变。
- 代码上与 v2 只差三处。




图 17: 同一个任务、同一份预算，三个算法的学习曲线。横轴用环境步数而不是墙钟——墙钟依赖当时跑在哪张卡上、有没有别的任务在抢，换台机器数字就变；环境步数是算法本身消耗的经验量，跨机器可比。浅色是逐迭代原始值，深色是滑动平均。**纵轴是训练时记的平均奖励。**v2/v3 那两条含一项 v1 没有的超时价值补偿（实测 +7.3%），所以三条线之间比的是形状与收敛快慢，绝对高低看上面那张评测表。

三级阶梯到此收口。从“拿分多的动作加概率”这一句直觉出发，加一个随状态变化的参照值（v2），再加一个限制更新幅度的护栏（v3），就得到了今天工业界训练机器人步态的默认配方。

下一节做一件不一样的事：**这套配方一行不改，只换奖励函数**，看它还能学出什么。

7 一套 PPO，换个奖励就是另一件事

前三节把一个算法从最朴素调到工业级，用的一直是同一个任务。这一节反过来：**算法一行不改，只换奖励函数**，看它能学出什么。

这一节的写法与前面不同。它不推导、不讲新机制，而是一个任务接一个任务地看：这个动作要什么、奖励表改了哪几项、我们跑出来什么。看点在图。




图 18: v3 PPO 最终策略走路的一个片段，六帧（第 60 / 100 / 140 / 179 / 219 / 259 步）。评测里 6400 个环境步零摔倒，脚离地时间 0.123 秒 —— 它是真在迈步，不是蹭地。

7.1 谱系总览：一个仓里三十三个任务，算法一行没改

小鸭子的训练仓里注册了 **33 个任务**（python code/env.py 打得出来）：**13 个平地主任务**，另外每个主任务多半还有一个“碎石地”孪生版和一个“带齿隙”孪生版（碎石地 10 个、带齿隙 15 个，两者有重叠）。按“改了什么”分成四类：

改的是什么	任务
换奖励	摔倒起身、坐 站、鼻尖取物、踢球、前滚翻
换脚	轮滑跟速度、左右蹬滑行、蹲着滑、滑下坡、从地上站到轮上、原地旋转
换地形	上面多数任务都有一个“碎石地”孪生版
换本体保真度	每个主任务都有一个“带齿隙”孪生版（每个舵机串 ± 1 度空程）

代码上，换任务就是改 code/env.py 顶部那一行：

```
# 换成上表里任意一个 task id
_DEFAULT_TASK = "Mjlab-Velocity-Flat-MicroDuck"
```

（批量跑的时候不必改文件——RL_DUCK_TASK 这个环境变量按进程覆盖它，一台机器七张卡各跑一个动作，靠的就是这个。）

训练脚本、网络结构、超参、评测口径，全都不动。本篇从这张表里挑了几个动作训，每个都是同一份 `train_v3_ppo.py`，只有 `_DEFAULT_TASK` 那一行不同。

下面的编排是：**8.2–8.5 各是一个训出来的动作**，8.6 与 8.7 是从这批任务的奖励表里拆出来的两条通用设计经验，8.8 把前面各节的奖励表并排读出几条规矩。

为什么能这样。3.8 节提过 `mjlab` 把环境拆成一组管理器：奖励、终止条件、指令生成、域随机化、课程表，每一样都是配置。**这些东西全在环境这一侧，不在算法里。**所以换掉训练算法它们照样生效，换掉任务训练算法也不用改。7.9 节会把这一点讲透。

7.2 脚下装上轮子：轮滑




图 19: 脚下换成被动轮之后的策略。六只鸭子同时跑，各自追自己的速度指令——它们都稳稳站在轮子上，靠上身摆动和腿部蹬地产生推力。

要什么。任务和走路完全一样——按速度指令移动、保持直立。唯一的区别在机器人本体：脚掌换成了四个**被动轮**（不带驱动，只能滚）。

奖励改了什么。几乎没改。它用的是同一套速度跟踪奖励。

跑出来什么。成了。它学出来的不是走，是滑——靠上身摆动和腿部蹬地产生推力，然后让轮子滚起来。同一套奖励、同一套算法，换掉脚就长出了完全不同的运动模式。

这个任务是这一节最干净的一个例子：**奖励几乎没动，行为却完全变了**。所谓“策略学的是怎么用这个身体拿分”，这就是字面意思——身体一换，怎么拿分的答案也换。

7.3 原地转起来：旋转




图 20: 原地旋转。六只鸭子这一瞬间各自转到了不同角度——一张静态图里能看出转速的，正是这种相位散开。

要什么。站在轮子上原地快速旋转。

奖励改了什么。主项从“跟上线速度”换成“跟上一个很高的转向角速度”。

跑出来什么。成了。

这个任务顺带说明一件容易搞错的事：**别用人的尺度去给机器人设限**。一个 25 厘米高的机器人，自然的旋转速度可以到每秒好几弧度——按人形机器人的直觉去加一个“转太快要扣分”的惩罚，会把这个动作直接掐死。上游的做法是：**不限制转速，而是限制冲击与抖动**（竖直加速度、动作变化率），让“转得快”和“转得野”分开。

7.4 低头，用嘴尖碰到地上的东西：取物

要什么。从站立姿态蹲下去，用嘴尖碰到地面上一个点，再站回来。

奖励改了什么。这是第一个目标不在“跟指令”而在“到某个空间位置”的任务。奖励表里多了：嘴尖到目标点的距离（高斯型）、蹲下过程中保持平衡、完成后回到站立姿态。

跑出来什么。成了。




图 21: 嘴尖取物的一个回合，按时间顺序取的六帧（第 60 / 100 / 140 / 179 / 219 / 259 步）。奖励只说了「嘴尖要到那个点」，「先蹲、再前倾、用膝和踝把身体压下去」这套动作是它自己找出来的。

这个任务的意义在于它换了目标的**类型**。前面所有任务的目标都是一个速度或姿态，是“整个身体处于什么状态”；这里的目标是**末端要够到一个点**，身体其余部分怎么配合由策略自己决定。奖励只说“嘴尖要到那儿”，它自己找出了“先蹲、再前倾、用膝和踝把身体压下去”这套动作。

7.5 翻过去再站起来：前滚翻

要什么。从站立开始，向前翻一个跟头，再站回来。

奖励改了什么。走路那套速度跟踪项（跟线速度、跟转向、腾空时间、抬脚高度、摆动腿高度、脚打滑、姿态）**七项全删**，换成一组围绕“翻过去再站住”的项。主项是翻滚进度（转过了多少角度），权重 **+8.0**。接着是一组管落地的：落地复合项 +4.0、落地尖峰 +2.0、翻完要直立 +1.5、翻完要站起高度 +1.0、起身速度 +0.75。反向的都很轻：别往侧翻 -0.5、别摊平 -0.5、转太快 -0.1、动作变化率 -0.1。

跑出来什么。**成了。**6000 迭代（它的课程表末档就在 6000，一分不多给），上面那十二帧就是最终权重跑出来的一个回合的前 230 步。

这一节值得细讲，因为它一个动作同时踩到三条规矩，而且每一条都有数。

一、挡动作的正则必须给得很轻（7.8 节规矩（6））。这里有确切的倍数。两个“挡动作”的正则项，同一个名字，在走路和前滚翻两张表里差得很远：

项	走路	前滚翻	倍数
躯干角速度	-0.05	-0.002	轻 25 倍
整机角动量	-0.02	-0.001	轻 20 倍




图 22: 前滚翻的一个回合，十二帧覆盖前 230 步（相邻帧 21 步）。第 0 步站立，第 21 步躯干前倾至水平、双脚离地，第 42 步整个倒过来（脚底朝上），第 62 步重新用双脚站住——整个翻滚约 1.2 秒；之后一百多步里它一直站着。

理由直白得几乎是同义反复：**前滚翻这个动作本身就是角动量**。按走路那个权重罚下去，等于对动作本身收重税，它永远学不会翻。规矩（6）在第 7 节是一句话，这两行是它的数。

二、“**别在坏状态上给正分**”是拿一整轮实验换来的（7.8 节规矩（5））。奖励表里有一项专门罚“翻完之后摊着不起来”，它的注释记着上游为这个动作烧掉一轮之后的结论：

带门限的落地奖励让“站起来”比“摊成一堆”更划算，**但摊着本身是免费的**——全部是正的门限项时，“保持摊着”每步收 0，那是一个舒服的盆地。盆地必须是净负的，才逼得出起身。

它的对策讲究之处在于带门限，只在翻滚完成之后才生效（按累计转过的角度开门）：翻滚过程本身不上税。惩罚落在“翻完之后该起来却不起”上，而不落在“正在尝试翻”上——后者会把动作的探索直接掐死。

三、它是十三个平地任务里唯一开对称性增广的。7.10 节会讲那是什么、为什么它必须写在算法侧而不是环境侧。这里先记一句，开它的那个任务，恰好也是唯一严格左右对称的动作。

7.6 插一段：目标可以完全不在观测里

前面四个动作有一个共同点容易被忽略：目标从来没有出现在策略的输入里。



图 23: 真机上的踢球：三只小鸭子和一个球。策略的 61 个输入里没有一个是关于球的——球在哪、多大、有没有被踢到，它全看不见。（厂商照片，Pollen Robotics）

拿踢球那个任务当例子最清楚。它的设定是：面前放一个 70 毫米、15 克的球，要把球往前踢开；奖励的主项是球往前走了多快。

而策略的观测就是 2.2 节那 61 个数字，全是本体感受和指令——球在哪、球有多大、球有没有被踢到，它一个都看不到。

那这个任务凭什么可解？因为目标全藏在奖励里。球往前走得快就加分，于是那些“恰好让球往前走”的动作被反复加强。策略最终长出来的不是“看见球、去踢它”，而是“在这个固定的初始布局下，做一套能把球送出去的动作”。

这件事对理解奖励的作用很关键：奖励不只是打分，它同时是任务定义的唯一载体。你想让机器人做什

么，全部信息都得进那张表——观测里没有的东西，只能靠奖励把它“暗示”出来。

反过来也成立，而且是这一节真正要说的：**观测里没有的东西，策略就没法泛化到它**。球换个位置、换个重量，这个策略不会调整——它压根不知道球存在。要让它“看见”球，得把球的状态加进观测，那就是另一个任务了。

7.7 插一段：“慢才是最优”怎么写进奖励

坐站那个任务（按指令在“坐”和“站”两个姿态之间切换，而且动作要轻、不许砸下去）的奖励表里有一个做法值得单独抄出来，它解决的是一类很常见的漏洞。

朴素的做法是“给速度加惩罚”。但那样有个漏洞——惩罚是有限的，而“早点到位、然后一直领到位的分”这个收益是按步累加的，冲过去反而更赚。正确的做法是：**追一个匀速推进的内部目标**。奖励只看“你离那个匀速目标有多近”，于是**抢跑得不到任何好处**——冲到目标前面，离匀速目标反而远了。慢下来成了最优解，不是因为快被罚，而是因为快没收益。

这个做法与具体任务无关，任何“要求匀速、要求柔和”的动作都能照抄：把“别太快”从一条惩罚改写成**一个会跟着时间走的目标**。7.8 节规矩（4）说的“不设一次性大奖”，讲的是同一件事的另一面。

7.8 写奖励的几条规矩

把这几张奖励表并排放在一起，能读出一些反复出现的规矩。每一条都配一个上面见过的实例。

（1）想要的动作要写成硬门，不是小额惩罚的暗示。踢球那项“支撑脚必须踩在地上”是一个硬条件，不满足就不给主项的分。如果换成“另一只脚离地要扣一点分”，策略会算账：扣的那点分比踢球拿的少，于是它会用一个双脚离地的凌空动作把球撞出去。**欠约束的自由度一定会被利用。**

（2）同一个目标分层写。起身与坐站的姿态和高度都写了两三层：一个宽的高斯项负责在离目标很远时提供梯度（不然一开始梯度接近零，学不动），一个窄的尖峰项负责最后那一点收口，再加一个 L1 项负责压掉常值偏差。单用一层要么远处没梯度，要么近处不够准。

（3）乘性复合打败加性求和。把几个条件加起来求和，会留下一个“每项都拿八成”的折中解——比如躯干歪着、高度差一点、但总分不低。改成几项相乘，任何一项不合格就整体归零，折中解消失。代价是每一项的容差要放宽到**当前策略够得着分**的程度，否则梯度看不见、什么都学不动。

（4）不设一次性大奖。“到达某状态就给一大笔”这种写法一定会被套利：提前冲到那个状态，然后按步一直领。对策是**限速或追一个匀速推进的内部目标**（7.7 节那个做法）。

（5）别在坏状态上给正分。比如“躺着的时候只要头抬起来就给分”——策略会找到那个最省力的躺姿，把头抬到刚好及格，然后一直躺着领分。对策是**按进度增量给分**：比上一刻更接近目标才给钱，保持不动不给。这样躺着领分就不成立了。

(6) 正则项分两类，上的时机不一样。一类是挡动作的（角速度、角动量、姿态偏离）——它们惩罚的正是动态动作物理上必须做的事，对翻滚、旋转这类任务要给得很轻。另一类是平滑类（动作变化率、力矩变化率）——它们不挡大动作，只挡抖动，可以给得重，但要等动作学会之后再上。走路那张表里“动作变化太快”的权重从 -0.1 分段拉到 -1.0 、第 1500 次迭代才到位（2.5 节讲过），就是这条规矩的实例：太早拉满，“什么都不做”就成了最优解。

7.9 一个身体，多个策略：观测布局与随时换脑

2.2 节留了一个伏笔：所有任务共用同一份 61 维观测布局，用不到的指令槽位填零而不是删掉。

现在可以说这为什么重要了。上面每个动作各自训出一个策略，它们的输入格式完全一样、输出格式也完全一样（61 进 14 出）。于是在同一台机器上，可以在任意时刻把当前生效的策略换成另一个——走着走着被推倒，切到起身策略；起来之后切回行走策略。

代价是每个策略都要接受一些它用不到的输入（比如走路策略也收到身体姿态指令，只是权重极小）。换来的是部署时的可组合性：一个身体，一组策略，随时切换。

这不是本篇的实验内容，但它解释了 2.2 节那个“看起来是浪费”的设计。

7.10 奖励表和课程表都在环境这一侧

这一节收一个容易被误解的点，它也是 mjlab 这种“管理器式”环境设计的要害。

奖励表、课程表、域随机化、回合起始状态的混合，全部写在环境配置这一侧，不在算法里。

后果有两个方向：

一，换算法它们照样生效。第 5-7 节那三份训练脚本，换成任何别的 PPO 实现，这些东西一个都不用重写。事实上本篇自己写的训练器与上游那套工业实现，在这几个任务上的超参是逐项相同的——实质差异只剩一个：训练跑多久。

二，换任务算法不用改。这一整节就是证据：_DEFAULT_TASK 换一行，换一个动作。

举一个具体的：走路那张表里“动作变化太快”这一项的权重不是常数，它由课程表从 -0.1 分段拉到 -1.0 、到第 1500 次迭代才到位。这条时间曲线在环境里，不在我们的代码里——所以它对 v1、v2、v3 三个算法一视同仁，三档对照才是干净的。

那有没有确实在算法侧的东西？有一个：对称性增广。

它的做法是把每一段经验的左右互换版本也拿来训——双足机器人是镜像对称的，所以“左腿这样、右腿那样”和它的镜像应当得到同一个决策。这一项不能写在环境里：它改的是 loss（多一项镜像一致性），而 loss 属于训练器。

于是训练器必须自己去问任务要不要它。本篇的 `train_v3_ppo.py` 就是这么做的——向任务注册表查这个任务的对称性配置，查到就把镜像一致性损失挂上去。**不在训练器里另存一份“哪个任务要开”的名单**：注册表是唯一声明处，抄一份出来，上游哪天改了开关，这边会静默失配。

13 个平地主任务，逐个查过它们的对称性配置，只有前滚翻是开的。那个动作是严格左右对称的，镜像一致性正好压住“往一侧塌”这个失败模式——正着翻要经过完全倒立的姿态，而往一侧塌是一条能量更低的斜路。

而 7.5 节那一档确实翻出来了：十二帧里站立 → 前倾 → 倒立 → 站回，整个动作约 1.2 秒。**唯一开对称性增广的任务，恰好也是唯一严格左右对称的动作，而它成了。**这个对照说明了那一项在什么时候才成为必需：动作本身有对称性可利用时才值得付这个代价，其余十二个任务把它关着，一样把各自的动作学了出来。

8 本讲小结

8.1 一条演进链：每一步为什么发生

回头看那三级阶梯，每一步都是被上一步的毛病逼出来的：

版本	加了什么	为了解决
v1 REINFORCE	策略梯度 + 常数基线	没有标准答案时怎么调参数
v2 A2C	critic 估值 + GAE 优势	v1 的参照值太粗，把功劳和罪责算错人
v3 PPO	概率比值 clip + 数据复用 + KL 自适应	v2 的更新步子没人管，走坏一步回不来

这条链上没有一步是“因为更先进所以用它”。每一步都对应一个具体的、在同一个任务上看得见的失败。

8.2 一张小结表：同一套算法，几个不同的动作

动作	改了什么	训练预算	拿到了什么
走路（平地）	—— 基准	6000 迭代	评测 0.155、6400 个环境步里零摔倒
轮滑	只换本体（脚 → 被动轮）	2000 迭代	长出完全不同的运动模式：靠上身摆动蹬地，让轮子滚起来
原地旋转	主项换成高转速跟踪	2000 迭代	站在轮上原地转起来
鼻尖取物	目标类型换成空间点	2000 迭代	自己找出“先蹲、再前倾、用膝盖把身体压下去”
前滚翻	主项换成“转过了多少角度”， 挡动作的正则砍到 1/20	6000 迭代	站立 → 前倾 → 倒立 → 站回， 约 1.2 秒；之后一百多步站着

这张表的“训练预算”一列也是结论的一部分。中间四个动作只用了 2000 迭代，而它们的课程表末档分别在第 5000、3000、2000、1000 迭代 —— 末档那几级做的都是加宽域随机化，不是搭技能脚手架，所以短跑也出得来动作。前滚翻不一样：它的课程表末档就在 6000，而那几级课程正是把翻滚从“站着不动”里推出来的东西。给一个新动作定预算，看的是它自己那份课程表的末档在第几迭代、以及末档那几级在加噪声还是在搭脚手架。

8.3 还能往哪走

本篇停在“on-policy、无模型、基于策略”这一格。地图上还有两个方向：

- **off-policy**：把经历存进池子反复抽用，样本效率高得多。代价是要处理“用旧数据学新策略”的偏差。
- **后训练**：不从零学，而是拿一个已经会做事的大模型，用强化学习去改进它。

这两条都不构成本篇的前置或后续——读到这里，你已经有一套能自己训出机器人动作的完整流程了。